

THU THẬP, TIỀN XỬ LÝ DỮ LIỆU KHÍ TƯỢNG VÀ PM2.5 DỰ BÁO TẠI TP.HCM

24521157

Lương Trần Kim Ngọc
Ngành Khoa học Dữ liệu
Đại học Công nghệ Thông tin

24521196

Nguyễn Phương Nguyên
Ngành Khoa học Dữ liệu
Đại học Công nghệ Thông tin

Tóm tắt nội dung—Dự báo nồng độ bụi mịn PM2.5 đóng vai trò quan trọng trong quản lý chất lượng không khí đô thị, tuy nhiên hiệu quả dự báo thường bị ảnh hưởng bởi tính khuyết thiếu và bất đồng bộ của dữ liệu môi trường. Nghiên cứu này đề xuất một pipeline tiền xử lý dữ liệu cho bài toán dự báo PM2.5 tại TP.HCM dựa trên dữ liệu đa nguồn từ OpenAQ [4] và Open-Meteo [5]. Khung đánh giá DMES [11] được áp dụng nhằm chuẩn hóa dữ liệu theo các tiêu chí về tính toàn vẹn, tính chính xác, tính nhất quán và tính kịp thời. Pipeline xử lý bao gồm chẩn đoán cơ chế khuyết thiếu, nội suy chuỗi thời gian, chuẩn hóa dữ liệu sau phân chia tập dữ liệu nhằm giảm thiểu hiện tượng rò rỉ dữ liệu, cùng các kỹ thuật đặc trưng như phân tích ACF/PACF, mã hóa chu kỳ và biến tương tác khí tượng. Kết quả thực nghiệm cho thấy quy trình tiền xử lý đề xuất cải thiện đáng kể hiệu năng dự báo, trong đó mô hình XGBoost đạt kết quả tốt nhất. Nghiên cứu nhấn mạnh vai trò của quản trị dữ liệu và kỹ thuật đặc trưng trong việc nâng cao hiệu quả dự báo chuỗi thời gian môi trường.

Keywords: PM2.5, tiền xử lý dữ liệu, DMES, feature engineering, XGBoost, data leakage.

I. GIỚI THIỆU

Ô nhiễm không khí hiện là một trong những thách thức môi trường và sức khỏe cộng đồng nghiêm trọng nhất trên toàn cầu, với tác động trực tiếp đến hệ hô hấp, tim mạch và chất lượng sống của con người. Trong số các chỉ số chất lượng không khí, PM_{2.5} — hạt vật chất có đường kính khí động học $\leq 2.5, \mu m$ — được xác định là tác nhân nguy hiểm hàng đầu do khả năng xâm nhập sâu vào phế nang và hệ tuần hoàn, làm gia tăng nguy cơ mắc các bệnh tim mạch, hô hấp mãn tính và ung thư phổi. Theo Tổ chức Y tế Thế giới (WHO), ô nhiễm không khí ngoài trời gây ra khoảng 4,2 triệu ca tử vong sớm mỗi năm trên toàn cầu [1]; riêng tại Việt Nam, con số này ước tính lên đến 60.000 ca hàng năm [2].

Thành phố Hồ Chí Minh (TP.HCM), với dân số trên 9 triệu người và mật độ phương tiện giao thông cao, hiện là một trong những đô thị chịu áp lực ô nhiễm không khí nghiêm trọng nhất tại khu vực Đông Nam Á [3]. Thực trạng này đặt ra yêu cầu cấp thiết về việc xây dựng các hệ thống dự báo chất lượng không khí có độ tin cậy cao, trong đó chất lượng dữ liệu đầu vào đóng vai trò then chốt quyết định hiệu quả của mô hình. Nhằm giải quyết yêu cầu trên, nghiên cứu này tập trung xây dựng một bộ dữ liệu tích hợp giữa nồng độ PM_{2.5} và các yếu tố khí tượng tại TP.HCM, đảm bảo tính nhất quán và khả năng tái lập, làm nền tảng cho các mô hình dự báo. Dữ liệu được thu thập theo giờ trong giai đoạn từ tháng 11 năm 2024 đến

tháng 5 năm 2026 tại các trạm quan trắc trên địa bàn thành phố, bao gồm chuỗi thời gian PM_{2.5} từ nền tảng OpenAQ [4] và các biến khí tượng — nhiệt độ, độ ẩm, lượng mưa, tốc độ và hướng gió — từ Open-Meteo [5]. Kết quả đầu ra là một tập dữ liệu đã qua làm sạch, đồng bộ hóa thời gian và xử lý giá trị khuyết thiếu cùng giá trị ngoại lai, có thể phục vụ cho mục đích phân tích thống kê và huấn luyện mô hình học máy. Các đóng góp chính của nghiên cứu bao gồm:

- Xây dựng pipeline thu thập và tích hợp dữ liệu đa nguồn tự động cho TP.HCM giai đoạn 2024 – 2026.
- Đề xuất quy trình tiền xử lý toàn diện với xử lý giá trị khuyết thiếu, ngoại lai và đồng bộ hóa thời gian.
- Cung cấp bộ dữ liệu PM_{2.5} – khí tượng tích hợp theo giờ đã được kiểm chứng theo khung DMES.
- Phân tích tương quan đặc trưng và đánh giá sơ bộ một số mô hình học máy cơ sở.

Phần còn lại được tổ chức như sau: Phần II trình bày tổng quan các nghiên cứu liên quan và khung đánh giá DMES được sử dụng làm cơ sở đánh giá chất lượng dữ liệu. Phần III thu thập dữ liệu từ hai nguồn mở OpenAQ và Open-Meteo. Phần IV trình bày chi tiết quy trình tiền xử lý dữ liệu, là nội dung trọng tâm của nghiên cứu. Phần V trình bày kết quả phân tích thống kê và trực quan hóa dữ liệu. Phần VI đánh giá và so sánh chất lượng tập dữ liệu theo tiêu chí DMES, kết hợp đánh giá sơ bộ một số mô hình học máy cơ sở. Cuối cùng, Phần VII đưa ra kết luận và đề xuất các hướng phát triển tiếp theo.

II. TỔNG QUAN NGHIÊN CỨU VÀ KHUNG ĐÁNH GIÁ DMES

A. Tổng quan các nghiên cứu dự báo PM2.5

Bài toán dự báo nồng độ bụi mịn PM_{2.5} đã được nghiên cứu rộng rãi trên thế giới và là một trong những hướng nghiên cứu trọng tâm của lĩnh vực khoa học dữ liệu môi trường. Trong những năm gần đây, sự phát triển của Trí tuệ Nhân tạo (AI) đã thúc đẩy bước chuyển dịch mạnh mẽ từ các phương pháp thống kê truyền thống sang các thuật toán Học máy (Machine Learning - ML) và Học sâu (Deep Learning - DL) nhằm mô hình hóa tốt hơn mối quan hệ phi tuyến giữa nồng độ chất ô nhiễm, điều kiện khí tượng và yếu tố thời gian.

Trên phạm vi quốc tế, nghiên cứu tổng quan của Zhou và cộng sự (2024) sau khi rà soát hệ thống 1.967 bài báo đã khẳng định dự báo PM_{2.5} là lĩnh vực đang phát triển mạnh mẽ [6]. Kết quả cho thấy các hướng tiếp cận dựa trên học sâu đang chiếm ưu thế, bao gồm mạng nơ-ron tích chập (CNN), mạng bộ nhớ

dài ngắn hạn (LSTM), đơn vị lặp cổng (GRU), cơ chế chú ý (Attention) và các mô hình lai. Tuy nhiên, lĩnh vực này vẫn tồn tại những thách thức về sự thiếu chuẩn hóa trong quy trình tiền xử lý, mô tả dữ liệu và thiết lập thực nghiệm, đồng thời khả năng diễn giải của các mô hình phức tạp vẫn còn hạn chế [6]. Tương tự, Agbehadji và cộng sự (2024) nhấn mạnh rằng việc khai thác đồng thời dữ liệu ô nhiễm, khí tượng và thông tin không gian-thời gian là chìa khóa để nâng cao độ chính xác, nhưng hiệu quả dự báo vẫn phụ thuộc lớn vào kỹ thuật xử lý dữ liệu đa nguồn và chuẩn hóa đầu vào [7].

Tại Việt Nam, các nghiên cứu về dự báo $PM_{2.5}$ tuy còn hạn chế so với quốc tế nhưng đã ghi nhận một số kết quả đáng chú ý, đặc biệt tại khu vực Thành phố Hồ Chí Minh. Nghiên cứu của Minh và cộng sự đã đề xuất mô hình dự báo $PM_{2.5}$ cho TP.HCM dựa trên sự kết hợp giữa dữ liệu quan trắc, dữ liệu khí tượng và mô hình khí tượng WRF cùng sáu thuật toán học máy khác nhau. Kết quả thực nghiệm cho thấy mô hình Extra Trees Regression đạt hiệu năng tốt nhất với $RMSE = 7.68 \mu g/m^3$, $MAE = 5.38 \mu g/m^3$, $R^2 = 0.68$ và độ chính xác phân loại khoảng 74% [8]. Tiếp nối hướng nghiên cứu này, Nguyen và cộng sự đã phát triển và đánh giá các mô hình ML và DL trên tập dữ liệu khí tượng giai đoạn 2021–2023 tại TP. Hồ Chí Minh [9]. Qua thực nghiệm, sáu thuật toán gồm RF, XGB, SVR, ANN, GRNN và CNN được triển khai và so sánh, trong đó ANN đạt hiệu quả dự báo tốt nhất trên tập kiểm tra với chỉ số IOA đạt 0.736 [9]. Các công trình này cho thấy xu hướng nghiên cứu trong nước hiện nay chủ yếu tập trung mạnh vào việc xây dựng, tối ưu và nâng cao hiệu năng của các mô hình dự báo chất lượng không khí [8] [9].

Mặc dù các nghiên cứu trên đã đạt được nhiều thành tựu về mặt thuật toán, nhưng việc so sánh và kế thừa vẫn gặp nhiều rào cản do thiếu sự thống nhất trong quy trình xử lý dữ liệu đầu vào. Thực tế cho thấy, các công trình hiện nay [8] [9] sử dụng các nguồn dữ liệu khác biệt (như AirNow, NOAA, hoặc WRF), áp dụng các phương pháp xử lý giá trị thiếu và phân chia tập dữ liệu không đồng nhất. Điều này tạo ra một “khoảng trống” về tính chuẩn hóa và khả năng tái lập - một yếu tố then chốt trong nghiên cứu khoa học.

B. Khung đánh giá Dataset–Method–Experiment Standard và định vị đề tài theo nhóm tiêu chí Dataset của DMES

Để khắc phục tình trạng thiếu thống nhất nêu trên, Zhou và cộng sự đã đề xuất khung chuẩn Dataset–Method–Experiment Standard (DMES) [6]. Khung DMES đánh giá nghiên cứu theo ba nhóm tiêu chí chính: Dataset, Method và Experiment. Theo đó:

- **Dataset (Dữ liệu):** tập trung vào các yếu tố liên quan đến dữ liệu, bao gồm tính mở của dữ liệu, đặc trưng dữ liệu, độ phân giải thời gian, kích thước dữ liệu, số chiều dữ liệu, cách phân chia tập dữ liệu, quy trình tiền xử lý, chuẩn hóa và xử lý giá trị khuyết thiếu hoặc bất thường.
- **Method (Phương pháp):** tập trung vào kiến trúc mô hình, mã nguồn, quy trình huấn luyện và tính mới của phương pháp
- **Experiment (Thực nghiệm):** kiểm chứng các thiết lập thực nghiệm, chỉ số đo lường hiệu năng và phân tích so

sánh đối chứng (benchmarking).

Trong phạm vi nghiên cứu này, do mục tiêu trọng tâm không hướng tới việc phát triển các thuật toán dự báo mới, đề tài tập trung khai thác có chọn lọc nhóm tiêu chí Dataset của DMES làm cơ sở lý luận để chuẩn hóa dữ liệu đầu vào. Cách tiếp cận này trực tiếp giải quyết “khoảng trống nghiên cứu” về khả năng tái lập thông qua việc xây dựng một quy trình xử lý dữ liệu nghiêm ngặt, bao gồm: thu thập dữ liệu đa nguồn từ OpenAQ và Open-Meteo, xử lý các giá trị khuyết thiếu và bất thường, đồng bộ hóa thời gian và thực hiện chuẩn hóa dữ liệu sau phân chia. Đề tài được định vị là nghiên cứu chuyên sâu về chất lượng và độ tin cậy của tập dữ liệu thực nghiệm. Thay vì tập trung tối ưu hóa hiệu năng mô hình như các công trình tiền nhiệm [8] [9], nghiên cứu hướng tới việc thiết lập một pipeline tiền xử lý có hệ thống và mở. Việc áp dụng khung DMES không chỉ cung cấp một thước đo khách quan về chất lượng dữ liệu tại đô thị đặc thù như TP.HCM, mà còn đóng góp một bộ dữ liệu mở chuẩn hóa, làm tiền đề triển khai cho các mô hình dự báo nâng cao (Học sâu, Transformer, GNN) trong tương lai [6].

III. THU THẬP DỮ LIỆU

A. Thu thập dữ liệu tổng quát

Việc dự báo nồng độ bụi mịn $PM_{2.5}$ không thể chỉ dựa vào chuỗi số liệu ô nhiễm mà cần xem xét đầy đủ các yếu tố khí tượng ảnh hưởng mạnh đến sự phân tán và hình thành hạt bụi, chẳng hạn như nhiệt độ, độ ẩm tương đối, lượng mưa, tốc độ gió và hướng gió [1]. Vì vậy, nghiên cứu sử dụng kết hợp hai nguồn dữ liệu mở là OpenAQ [4] cho dữ liệu chất lượng không khí và Open-Meteo [5] cho dữ liệu khí tượng.

Hiện nay, các nền tảng cung cấp dữ liệu $PM_{2.5}$ phổ biến bao gồm IQAir, WAQI và PurpleAir. Mặc dù được sử dụng rộng rãi trong giám sát chất lượng không khí, các nền tảng này vẫn tồn tại một số hạn chế khi phục vụ mục đích thu thập dữ liệu lịch sử dài hạn cho nghiên cứu dự báo chuỗi thời gian.

IQAir giới hạn khả năng truy cập dữ liệu lịch sử thông qua API ở phạm vi ngắn hạn; dữ liệu dài hạn chủ yếu được công bố dưới dạng báo cáo tổng hợp định kỳ với độ phân giải thời gian thấp, chưa đáp ứng yêu cầu dữ liệu theo giờ của các mô hình dự báo [10]. WAQI cung cấp API miễn phí cho dữ liệu thời gian thực, tuy nhiên việc truy cập dữ liệu lịch sử yêu cầu cơ chế đăng ký riêng và chịu các ràng buộc về điều khoản sử dụng dữ liệu [11]. Đối với PurpleAir, các điểm truy cập dữ liệu lịch sử đã được hạn chế kể từ năm 2022 nhằm kiểm soát tải hệ thống; số lượng bản ghi truy xuất trong mỗi yêu cầu bị giới hạn, làm gia tăng số lượng truy vấn cần thiết khi thu thập dữ liệu quy mô lớn [12].

So với các nền tảng trên, OpenAQ đáp ứng tốt hơn các yêu cầu của nghiên cứu nhờ cung cấp API mở miễn phí với cấu trúc dữ liệu chuẩn hóa, cho phép truy xuất chuỗi thời gian lịch sử cùng đầy đủ thông tin về cảm biến và vị trí quan trắc [4]. Dữ liệu được tổng hợp từ mạng lưới các trạm quan trắc mặt đất trên phạm vi toàn cầu, cung cấp các giá trị đo thực tế kèm metadata chuẩn hóa, đáp ứng đồng thời yêu cầu về độ phân giải thời gian, khả năng truy xuất lịch sử và tính tái sử dụng trong nghiên cứu [4].

Đối với dữ liệu khí tượng, các nguồn dữ liệu phổ biến hiện nay bao gồm OpenWeather và NOAA/NCEI. OpenWeather cung cấp dịch vụ truy xuất dữ liệu lịch sử theo mô hình tính phí, dẫn đến chi phí tích lũy đáng kể khi thu thập dữ liệu dài hạn cho nhiều vị trí quan trắc [13]. NOAA/NCEI cung cấp kho dữ liệu lịch sử miễn phí nhưng áp dụng các giới hạn về tốc độ truy vấn và số lượng yêu cầu hàng ngày; đồng thời cấu trúc API tương đối phức tạp đối với các quy trình thu thập dữ liệu tự động quy mô lớn [14].

Open-Meteo cung cấp dữ liệu khí tượng theo giờ miễn phí dựa trên bộ dữ liệu tái phân tích ERA5 của ECMWF. Dữ liệu lịch sử được truy xuất thông qua Archive API, cho phép thu thập tự động theo tọa độ địa lý với định dạng dữ liệu nhất quán, phù hợp cho các nghiên cứu dự báo chuỗi thời gian [5].

Mặc dù Open-Meteo cung cấp dữ liệu $PM_{2.5}$, các giá trị này được ước tính từ mô hình chất lượng không khí thay vì thu nhận trực tiếp từ các trạm quan trắc mặt đất. Do nghiên cứu hướng tới dự báo nồng độ $PM_{2.5}$ thực tế tại TP.HCM, biến mục tiêu cần được xây dựng từ dữ liệu đo đạc thực địa nhằm đảm bảo tính đại diện của hiện tượng cần dự báo. Vì vậy, dữ liệu $PM_{2.5}$ từ OpenAQ được lựa chọn làm nguồn dữ liệu mục tiêu cho nghiên cứu [4].

Dữ liệu đầu vào được thu thập tự động với độ phân giải giờ, tập trung tại tọa độ trung tâm TP. Hồ Chí Minh (10,7769°N, 106,7009°E). Cụ thể, dữ liệu $PM_{2.5}$ từ OpenAQ truy xuất thông qua API, trong khi dữ liệu khí tượng từ Open-Meteo được gọi trực tiếp từ archive API. Sau khi thu thập, hai bộ dữ liệu được hợp nhất theo trường thời gian, kiểm tra tính toàn vẹn và làm sạch nghiêm ngặt trước khi tiến hành các bước tiền xử lý và kỹ thuật đặc trưng.

B. Thu thập dữ liệu $PM_{2.5}$ từ OpenAQ

Dữ liệu $PM_{2.5}$ được thu thập từ nền tảng OpenAQ thông qua API (ver3). Quy trình thu thập được thực hiện tự động theo ba giai đoạn chính:

- Xác định các location trong bán kính 25 km quanh trung tâm TP. Hồ Chí Minh thông qua endpoint `/v3/locations`.
- Trích xuất danh sách các sensor đo $PM_{2.5}$ tại từng location thông qua endpoint `/v3/locations/{id}/sensors`.
- Tải chuỗi dữ liệu đo theo giờ thông qua endpoint `/v3/sensors/{id}/hours`.

Mặc dù xác định được 11 sensors thuộc 11 locations, nhưng chỉ có 5 sensors cung cấp dữ liệu ổn định và có ý nghĩa thống kê trong giai đoạn nghiên cứu. Tập dữ liệu ban đầu thu được 20.927 bản ghi. Sau khi bổ sung dữ liệu mới từ giao diện web OpenAQ và thực hiện hợp nhất, tập dữ liệu thô cuối cùng gồm 21.678 dòng. Dữ liệu được nhóm theo giờ và tính giá trị trung bình từ 5 trạm quan trắc chính, thu được 11.555 quan sát hợp lệ trong khoảng thời gian từ ngày 19 tháng 11 năm 2024 đến ngày 10 tháng 5 năm 2026. Các giá trị bất thường (âm hoặc vượt quá $400 \mu\text{g}/\text{m}^3$) đã được loại bỏ để đảm bảo tính hợp lý vật lý.

Phương pháp kết hợp giữa thu thập tự động qua API và bổ sung dữ liệu gần nhất không chỉ nâng cao độ phủ và tính cập nhật của chuỗi thời gian mà còn đảm bảo tính minh bạch, khoa học và khả năng tái lập của nghiên cứu.

C. Thu thập dữ liệu khí tượng từ Open-Meteo

Dữ liệu khí tượng được trích xuất tự động từ Open-Meteo Archive API với các tham số được truy vấn bao gồm tọa độ trung tâm TP.HCM (10.7769° N, 106.7009° E), độ phân giải theo giờ và múi giờ Asia/Ho_Chí_Minh. Giai đoạn thu thập thu về 12.912 bản ghi, bao gồm 5 biến khí tượng cốt lõi:

- Nhiệt độ ở độ cao 2m (*temperature_2m*)
- Độ ẩm tương đối ở độ cao 2m (*relative_humidity_2m*)
- Tốc độ gió ở độ cao 10m (*wind_speed_10m*)
- Áp suất bề mặt (*surface_pressure*)
- Lượng mưa (*precipitation*)

D. Cấu trúc dữ liệu thô

Quá trình hợp nhất hai nguồn dữ liệu được thực hiện bằng phương pháp Left Join trên trường *time* làm khóa chính. Đồng thời, các đặc trưng thời gian cơ bản (*hour*, *month*, *dayofweek*) được trích xuất từ cột thời gian để hỗ trợ nhận diện chu kỳ tuần hoàn.

Bộ dữ liệu thô sau khi hợp nhất gồm 12.912 quan sát và 11 thuộc tính. Từ điển dữ liệu được trình bày chi tiết trong Bảng I.

E. Thống kê sơ bộ dữ liệu thu thập được

Phân tích sơ bộ dữ liệu thô cho thấy: Tính toàn vẹn của dữ liệu khí tượng: 100% đầy đủ (0% missing values). Tỷ lệ khuyết thiếu của $PM_{2.5}$: 10,51% (tương đương 1.357 trên 12.912 quan sát). Ma trận khuyết thiếu cho thấy các giá trị $PM_{2.5}$ bị thiếu không phân bố ngẫu nhiên mà tập trung thành các khoảng đứt gãy lớn. Những khoảng gap hệ thống này chủ yếu rơi vào các giai đoạn tháng 1 năm 2025, tháng 2 năm 2025 và tháng 6 năm 2025. Việc tồn tại các khoảng gap lớn là một trong những thách thức chính của bộ dữ liệu, sẽ được xử lý chi tiết ở phần tiền xử lý (Chương IV).

IV. TIỀN XỬ LÝ DỮ LIỆU

Kết quả thống kê sơ bộ cho thấy dữ liệu thu thập tồn tại một số vấn đề về tính liên tục của chuỗi thời gian, bao gồm các khoảng đứt gãy, giá trị khuyết thiếu và sự không đồng nhất về định dạng giữa các nguồn dữ liệu. Nếu không được xử lý thích hợp, những vấn đề này có thể ảnh hưởng đến chất lượng dữ liệu đầu vào, từ đó làm suy giảm độ tin cậy của các kết quả phân tích và dự báo.

Do đó, nghiên cứu xây dựng một pipeline tiền xử lý gồm năm bước chính: (1) chuẩn hóa thời gian và đơn vị đo lường; (2) phát hiện và xử lý các khoảng đứt gãy dữ liệu; (3) chẩn đoán cơ chế và xử lý giá trị khuyết thiếu; (4) nhận diện và quản lý giá trị ngoại lai; và (5) tích hợp dữ liệu $PM_{2.5}$ với dữ liệu khí tượng thành một tập dữ liệu thống nhất. Pipeline được thiết kế nhằm bảo đảm tính nhất quán, độ tin cậy và khả năng tái lập của bộ dữ liệu, tạo nền tảng cho các bước phân tích khám phá dữ liệu và xây dựng mô hình dự báo trong các phần tiếp theo.

A. Chuẩn hóa định dạng thời gian và đơn vị đo lường

Dữ liệu trong nghiên cứu này được thu thập từ hai nguồn chính: nồng độ bụi mịn $PM_{2.5}$ từ nền tảng OpenAQ và các biến khí tượng từ Open-Meteo. Sự khác biệt về định dạng *timestamp* và múi giờ đòi hỏi một quy trình chuẩn hóa nghiêm ngặt trước khi thực hiện hợp nhất (merge).

Bảng I: Từ điển dữ liệu của bộ tập dữ liệu nghiên cứu

Tên biến	Kiểu dữ liệu	Đơn vị	Mô tả chi tiết	Phân loại
time	Datetime	–	Mốc thời gian quan trắc (độ phân giải giờ)	Khóa/Index
pm25	Float	$\mu\text{g}/\text{m}^3$	Nồng độ PM _{2.5} trung bình theo giờ	Biến mục tiêu
temperature	Float	°C	Nhiệt độ ở độ cao 2m	Biến đầu vào
humidity	Float	%	Độ ẩm tương đối ở độ cao 2m	Biến đầu vào
wind_speed	Float	km/h	Tốc độ gió ở độ cao 10m	Biến đầu vào
pressure	Float	hPa	Áp suất bề mặt	Biến đầu vào
precipitation	Float	mm	Lượng mưa theo giờ	Biến đầu vào
n_obs	Integer	–	Số trạm PM _{2.5} có dữ liệu trong giờ đó	Biến hỗ trợ
hour	Integer	–	Giờ trong ngày (0–23)	Đặc trưng chu kỳ
month	Integer	–	Tháng trong năm (1–12)	Đặc trưng chu kỳ
dayofweek	Integer	–	Thứ trong tuần (0 = Thứ 2, 6 = Chủ nhật)	Đặc trưng chu kỳ

1) Đồng bộ múi giờ và định dạng thời gian

Dữ liệu thô từ OpenAQ được lưu trữ chủ yếu theo múi giờ UTC với cột *datetimeUtc*, trong khi Open-Meteo trả về chuỗi thời gian theo định dạng ISO 8601 theo múi giờ được chỉ định. Để phù hợp với ngữ cảnh nghiên cứu tại TP. Hồ Chí Minh, toàn bộ dữ liệu được chuyển về múi giờ Asia/Ho_Chi_Minh (ICT, UTC+7) – múi giờ địa phương. Việc lựa chọn này không chỉ đảm bảo tính nhất quán mà còn cho phép các đặc trưng chu kỳ (hour, dayofweek) phản ánh đúng hoạt động kinh tế - xã hội thực tế tại TP.HCM. Nếu giữ múi giờ UTC, các đặc trưng theo giờ trong ngày sẽ bị lệch pha so với thực tế, dẫn đến giảm khả năng học của mô hình về quy luật ngày-đêm và giờ cao điểm giao thông. Các bước thực hiện bao gồm:

- Chuyển đổi múi giờ từ UTC sang ICT và loại bỏ timezone information (tz_localize(None)).
- Chuyển kiểu dữ liệu sang datetime64[ns].
- Sau khi chuyển đổi múi giờ, dữ liệu được lưu dưới định dạng datetime64[ns] và sử dụng làm khóa thời gian trong quá trình hợp nhất, nội suy và xây dựng đặc trưng.

Listing 1: Ví dụ code (đã thực hiện trong notebook)

```
df_pm25['time'] = pd.to_datetime(df_pm25['datetimeUtc'], utc=True)
df_pm25['time'] = df_pm25['time'].dt.tz_convert('Asia/Ho_Chi_Minh').dt.tz_localize(None)
```

Sau bước chuẩn hóa, tập dữ liệu PM_{2.5} bao phủ khoảng 11.555 bản ghi hợp lệ trong giai đoạn từ 19/11/2024 đến 10/05/2026, với tần suất giờ.

2) Thống nhất đơn vị đo lường

Tất cả các biến khí tượng từ Open-Meteo đã được trả về với đơn vị chuẩn (nhiệt độ °C, độ ẩm %, tốc độ gió km/h, áp suất hPa, lượng mưa mm). Không có biến nào cần chuyển đổi đơn vị vật lý. Các giá trị bất thường (ví dụ: PM_{2.5} âm hoặc lớn hơn 400 $\mu\text{g}/\text{m}^3$) được xử lý như các giá trị thiếu (missing values) ở bước tiếp theo.

Sau khi chuẩn hóa, hai bảng dữ liệu được hợp nhất (merge) trên cột (*time*) theo phương pháp left join, thu được tập dữ liệu hoàn chỉnh gồm 12.912 quan sát theo giờ.

B. Phát hiện và xử lý khoảng đứt gãy dữ liệu

Trong quá trình phân tích dữ liệu, nghiên cứu phát hiện ba khoảng đứt gãy lớn trong chuỗi PM_{2.5} với độ dài vượt quá 7 ngày liên tục. Đối với dữ liệu chuỗi thời gian, các khoảng thiếu kéo dài có thể làm gián đoạn cấu trúc phụ thuộc theo thời gian và làm suy giảm độ tin cậy của các phương pháp nội suy.

Do đó, ngưỡng *gap_threshold_days* = 7 được thiết lập, bởi giá trị này tương ứng với một chu kỳ tuần - đơn vị thời gian then chốt trong việc xây dựng các đặc trưng trễ (lag features) và phân tích tính mùa vụ, đồng thời phù hợp với các đặc trưng trễ được sử dụng trong bài toán dự báo PM_{2.5}. Các khoảng đứt gãy vượt quá ngưỡng được xem là không cung cấp đủ thông tin ngữ cảnh để khôi phục dữ liệu một cách đáng tin cậy.

Đối với các khoảng đứt gãy lớn, phương pháp loại bỏ được lựa chọn thay cho nội suy vì các lý do sau:

- **Bảo toàn cấu trúc thời gian:** Nội suy trên các khoảng trống kéo dài có thể làm sai lệch mối quan hệ phụ thuộc theo thời gian của chuỗi, đặc biệt đối với các đặc trưng trễ như lag * 24 và lag * 168.
- **Hạn chế sai lệch do dữ liệu tổng hợp:** Các giá trị được tạo ra từ nội suy trên khoảng thiếu lớn chủ yếu phản ánh giả định của phương pháp nội suy thay vì diễn biến thực tế của môi trường, từ đó có thể ảnh hưởng đến khả năng học của mô hình dự báo. “

Quyết định này dẫn đến việc loại bỏ 40,3% tổng số quan sát. Mặc dù làm giảm quy mô tập dữ liệu, nhưng điều này đảm bảo chất lượng của chuỗi thời gian còn lại đạt độ liên tục cao và có giá trị tin cậy cho quá trình huấn luyện.


C. Chẩn đoán và xử lý giá trị khuyết thiếu (Missing Values)

Giá trị khuyết thiếu là một thách thức phổ biến trong dữ liệu quan trắc môi trường, đặc biệt khi tích hợp nhiều nguồn dữ liệu có tần suất và độ phủ khác nhau. Trong nghiên cứu này, sau khi hợp nhất dữ liệu nồng độ PM_{2.5} từ OpenAQ với dữ liệu khí tượng từ Open-Meteo, biến mục tiêu pm25 ghi nhận tỷ lệ khuyết thiếu là 10,51% (1.357 trên tổng số 12.912 quan sát theo giờ). Việc xử lý missing values một cách khoa học và cẩn trọng là bước quan trọng nhằm đảm bảo tính toàn vẹn

dữ liệu và tránh thiên kiến trong quá trình xây dựng mô hình dự báo.

1) **Chẩn đoán cơ chế khuyết thiếu**

Trước khi lựa chọn phương pháp imputation, nghiên cứu đã tiến hành phân tích toàn diện cơ chế khuyết thiếu thông qua các công cụ trực quan và thống kê.



Hình 1: So sánh phân phối có điều kiện của các biến khí tượng giữa PM_{2.5} có dữ liệu và PM_{2.5} khuyết thiếu


Hình 1 trình bày kết quả phân tích trực quan nhằm chẩn đoán cơ chế khuyết thiếu của biến $PM_{2.5}$. Phân phối của các biến khí tượng, bao gồm nhiệt độ, độ ẩm, tốc độ gió và áp suất, giữa nhóm quan sát có dữ liệu $PM_{2.5}$ và nhóm khuyết thiếu cho thấy mức độ tương đồng cao, thể hiện qua sự chồng lấp đáng kể của các đường phân phối ở tất cả các biến. Kết quả này cho thấy khả năng xuất hiện giá trị khuyết thiếu không phụ thuộc rõ ràng vào giá trị của các biến khí tượng được quan sát. Bên cạnh đó, ma trận mẫu khuyết thiếu cho thấy hiện tượng khuyết thiếu chỉ xảy ra tại biến $PM_{2.5}$ và không đi kèm với sự khuyết thiếu ở các biến khí tượng khác, phù hợp với đặc điểm dữ liệu được thu thập từ hai hệ thống quan trắc độc lập. Những quan sát này cung cấp bằng chứng thực nghiệm cho thấy cơ chế khuyết thiếu của tập dữ liệu thuộc dạng khuyết thiếu hoàn toàn ngẫu nhiên (MCAR – Missing Completely At Random), tạo cơ sở tin cậy cho việc áp dụng các phương pháp nội suy ở bước tiếp theo mà không làm phát sinh sai lệch có hệ thống trong dữ liệu.



Hình 2: Mẫu khuyết thiếu theo thời gian và phân phối của nồng độ PM_{2.5} trong dữ liệu thô

Hình 2 minh họa mô hình khuyết thiếu của biến $PM_{2.5}$ trên trục thời gian từ tháng 11/2024 đến tháng 5/2026. Kết quả cho thấy dữ liệu tồn tại các khoảng khuyết thiếu ngắn (từ vài giờ

đến vài ngày) xen kẽ với một số khoảng trống lớn hơn 7 ngày. Những khoảng trống (gap) lớn này đã được nhận diện thông qua quy trình gap detection với ngưỡng `gap_threshold_days = 7` trong tệp cấu hình (CONFIG), và được xử lý tách biệt trong giai đoạn làm sạch dữ liệu để tránh gây nhiễu cho quá trình nội suy.



Hình 3: Phân phối PM_{2.5} và dữ liệu thô

Biểu đồ phía dưới trình bày đặc điểm phân phối của nồng độ $PM_{2.5}$ trong tập dữ liệu thô. Phân phối này thể hiện rõ tính lệch phải với giá trị trung vị là $31,2 \mu\text{g}/\text{m}^3$ — cao hơn gấp đôi so với ngưỡng khuyến cáo hàng ngày của Tổ chức Y tế Thế giới (WHO) là $15 \mu\text{g}/\text{m}^3$. Việc chuyển đổi sang thang đo logarit ($\log(PM_{2.5} + 1)$) ở biểu đồ bên phải giúp chuẩn hóa phân phối và làm rõ hơn sự hiện diện của các giá trị ngoại lai cực đoan.

Kết hợp với phân tích phân phối có điều kiện tại Hình 4.1 và kết quả kiểm định Little's MCAR ($p\text{-value} > 0,05$) đối với các khoảng khuyết thiếu ngắn, nghiên cứu kết luận rằng phần lớn các giá trị thiếu thuộc cơ chế MCAR hoặc MAR. Điều này cho phép áp dụng các phương pháp nội suy cho các khoảng trống nhỏ mà vẫn đảm bảo tính khách quan của dữ liệu.

2) **Chiến lược xử lý dữ liệu khuyết thiếu (Imputation)**

Vì đặc thù của bài toán dự báo chuỗi thời gian, nghiên cứu đã áp dụng chiến lược nội suy riêng biệt cho từng tập dữ liệu Huấn luyện, Kiểm định và Kiểm tra sau khi đã phân chia theo trục thời gian. Phương pháp này nhằm triệt để loại bỏ hiện tượng rò rỉ dữ liệu, đảm bảo rằng thông tin từ tương lai không ảnh hưởng đến quá trình huấn luyện và đánh giá mô hình. Quy trình xử lý cụ thể được thực hiện như sau:

- **Đối với biến mục tiêu PM_{2.5}:** Sử dụng phương pháp nội suy tuyến tính dựa trên mốc thời gian với giới hạn tối đa 3 giờ liên tiếp.
- **Đối với các biến khí tượng:** Áp dụng phương pháp lấp đầy tiến (Forward Fill) với giới hạn tối đa 3 giờ.
- **Quản lý dữ liệu:** Thiết lập biến cờ `pm25_interpolated` để định danh các quan sát đã qua xử lý nội suy, phục vụ cho việc kiểm soát chất lượng và đánh giá sai số.

Sau quá trình nội suy, các quan sát vẫn còn khuyết thiếu (do khoảng trống vượt quá giới hạn 3 giờ) sẽ bị loại bỏ để đảm bảo tính toàn vẹn và độ tin cậy của dữ liệu đầu vào cho mô hình.

Việc lựa chọn các phương pháp nội suy cục bộ thay vì các phương pháp toàn cục (như trung bình/trung vị) hoặc các mô hình phức tạp như MICE là nhằm bảo toàn tính tự tương quan thời gian của dữ liệu. Điều này đặc biệt quan trọng trong bài toán dự báo ngắn hạn (1 giờ tới), nơi các giá trị gần kề có

mối liên hệ chặt chẽ hơn so với phân phối tổng thể của toàn bộ tập dữ liệu.

Listing 2: Quy trình thực hiện nội suy dữ liệu sau khi phân chia tập dữ liệu

```
weather_cols = ['temperature', 'humidity', 'wind_speed', 'pressure', 'precipitation']
for df_part in [df_train, df_val, df_test]:
    df_part.set_index('time', inplace=True)
    df_part['pm25_interpolated'] = df_part['pm25'].isna()


    df_part['pm25'] = df_part['pm25'].interpolate(
        method='time',
        limit=CONFIG['interpolate_limit_hours']
    )

    for col in weather_cols:
        df_part[col] = df_part[col].ffill(limit=CONFIG['ffill_limit_hours'])

    df_part.reset_index(inplace=True)

    df_part.dropna(subset=['pm25'] + weather_cols, inplace=True)
    df_part.reset_index(drop=True, inplace=True)
```

3) Kiểm chứng chất lượng Imputation



Hình 4: Kết quả kiểm tra nội suy giả lập

Để đánh giá độ tin cậy và tính ổn định của chiến lược nội suy, nhóm nghiên cứu thực hiện kiểm tra nội suy giả lập (Synthetic Removal Test). Phương pháp này mô phỏng quá trình khuyết thiếu bằng cách ngẫu nhiên loại bỏ một số giá trị $PM_{2.5}$ đã biết trong tập Huấn luyện, sau đó áp dụng quy trình nội suy và so sánh kết quả với giá trị thực tế ban đầu.

Kết quả phân tích tại **Hình 4** cho thấy:

- **Độ chính xác của giá trị nội suy:** Biểu đồ phân tán cho thấy các điểm dữ liệu tập trung sát đường chéo (perfect imputation) với hệ số xác định $R^2 = 0,9143$. Điều này chứng minh phương pháp nội suy giải thích được hơn 91% biến thiên của dữ liệu thực tế. Sai số tuyệt đối trung bình ($MAE = 3,759 \mu g/m^3$) ở mức thấp so với biên độ biến động của nồng độ $PM_{2.5}$.
- **Phân phối sai số:** Biểu đồ histogram trình bày phân phối sai số nội suy. Sai số phân bố đối xứng quanh giá trị 0 với sai số trung bình là $0,499 \mu g/m^3$, cho thấy phương pháp nội suy không gây ra sai số hệ thống. Hầu hết các sai số nằm trong khoảng $\pm 10 \mu g/m^3$, khẳng định hiệu quả của phương pháp nội suy tuyến tính với giới hạn 3 giờ đối với các khoảng khuyết thiếu ngắn.


Kết quả từ Synthetic Removal Test khẳng định chiến lược nội suy được lựa chọn là đáng tin cậy và phù hợp với đặc điểm của tập dữ liệu. Đáng chú ý, sai số nội suy ($MAE \approx 3,76 \mu g/m^3$) thấp hơn đáng kể so với sai số dự báo của các mô hình cơ sở ở các giai đoạn sau (thường $MAE > 8-10 \mu g/m^3$). Điều này đảm bảo chất lượng dữ liệu đầu vào cho các bước kỹ thuật đặc trưng và huấn luyện mô hình mà không gây ra sai số đáng kể cho kết quả dự báo cuối cùng.

D. Phân chia tập dữ liệu (Train/Validation/Test)

Trong bài toán dự báo chuỗi thời gian, việc phân chia dữ liệu phải tuân thủ nghiêm ngặt thứ tự thời gian nhằm ngăn chặn hiện tượng rò rỉ dữ liệu (data leakage). Do chuỗi nồng độ $PM_{2.5}$ tồn tại tính tự tương quan và các thành phần mùa vụ rõ rệt, nghiên cứu sử dụng phương pháp phân chia theo mốc thời gian (chronological split) thay vì lấy mẫu ngẫu nhiên hoặc kiểm chéo K-fold. Cách tiếp cận này đảm bảo rằng mô hình chỉ được huấn luyện trên dữ liệu quá khứ và được đánh giá trên các quan sát xảy ra sau đó, phản ánh đúng kịch bản vận hành thực tế.

Dựa trên các mốc thời gian được xác định trước, tập dữ liệu gồm 7.706 quan sát được phân chia thành ba tập như sau:

- **Tập huấn luyện (Train):** 4.586 quan sát, từ 23/06/2025 đến 31/12/2025.
- **Tập xác thực (Validation):** 1.416 quan sát, từ 01/01/2026 đến 28/02/2026.
- **Tập kiểm tra (Test):** 1.704 quan sát, từ 01/03/2026 đến 10/05/2026.



Hình 5: Timeline phân chia tập Train, Validation và Test


Chiến lược phân chia này đảm bảo tập Train đủ lớn để mô hình học được các quy luật dài hạn và tính mùa vụ của dữ liệu, trong khi tập Validation được sử dụng cho quá trình hiệu chỉnh mô hình và tập Test đóng vai trò đánh giá khách quan hiệu năng trên dữ liệu chưa từng được quan sát. Để đảm bảo tính toàn vẹn của quá trình thực nghiệm, toàn bộ các bước nội suy, phát hiện ngoại lai, xây dựng đặc trưng và chuẩn hóa dữ liệu đều được thực hiện sau khi phân chia dữ liệu; các tham số chuẩn hóa chỉ được ước lượng trên tập Train và sau đó áp dụng cho tập Validation và Test.

E. Phân tích và xử lý giá trị ngoại lai (Outliers)

Dữ liệu $PM_{2.5}$ thường chứa nhiều giá trị ngoại lai do ảnh hưởng của các sự kiện bất thường như ô nhiễm cục bộ mạnh, cháy rừng, khói công nghiệp hoặc lỗi kỹ thuật từ cảm biến. Việc phát hiện và xử lý các giá trị ngoại lai một cách hợp lý là cần thiết nhằm giảm nhiễu cho mô hình, đồng thời vẫn phải bảo toàn được thông tin thực tiễn về các đợt ô nhiễm cực đoạn.

1) Phân tích phân phối và phát hiện giá trị ngoại lai

Để xác định và xử lý các giá trị ngoại lai một cách khách quan, nhóm đã thực hiện phân tích chuyên sâu trên tập huấn luyện thông qua nhiều góc nhìn khác nhau (Hình 7).



Hình 6: Kết quả kiểm tra nội suy giả lập


Kết quả phân tích chi tiết như sau:

- **Đặc điểm phân phối:** Biểu đồ boxplot cho thấy sự phân tách rõ rệt giữa nhóm bình thường và nhóm ngoại lai. Nhóm ngoại lai có giá trị trung vị khoảng $82 \mu\text{g}/\text{m}^3$ và một số giá trị cực đoan vượt quá $140 \mu\text{g}/\text{m}^3$. Ngưỡng phát hiện dựa trên khoảng tứ phân vị (IQR) được xác định trong khoảng $[-7, 4, 68, 3] \mu\text{g}/\text{m}^3$.
- **Tương quan theo thời gian:** Biểu đồ tỷ lệ outlier theo giờ cho thấy các giá trị ngoại lai tập trung mạnh nhất vào khung giờ 6h–7h và kéo dài trong khoảng từ 5h đến 8h sáng với tỷ lệ lên đến 7,8–8%. Điều này cho thấy hiện tượng ô nhiễm cực đoan không diễn ra ngẫu nhiên mà có mối liên hệ chặt chẽ với giờ cao điểm giao thông và các hoạt động công nghiệp buổi sáng tại TP.HCM.
- **Tương quan với biến khí tượng:** Hai biểu đồ phân phối mật độ cho thấy sự khác biệt rõ rệt về điều kiện khí tượng khi xảy ra ô nhiễm mạnh. **Về nhiệt độ**, nhóm ngoại lai có xu hướng tập trung ở ngưỡng nhiệt độ cao hơn so với nhóm bình thường, cho thấy sự tương quan thuận giữa nhiệt độ tăng và nồng độ bụi mịn. **Về tốc độ gió**, nhóm ngoại lai tập trung chủ yếu trong khoảng vận tốc thấp (0–7 km/h). Điều này hoàn toàn phù hợp với lý thuyết khí tượng: khi nhiệt độ tăng kết hợp với tốc độ gió thấp, khả năng khuếch tán chất ô nhiễm trong khí quyển bị hạn chế đáng kể, dẫn đến hiện tượng tích tụ $\text{PM}_{2.5}$ nồng độ cao tại bề mặt.

2) Chiến lược xử lý giá trị ngoại lai

Thay vì loại bỏ các giá trị ngoại lai, nhóm quyết định giữ nguyên chúng và triển khai chiến lược quản lý thông qua việc tạo biến cờ `pm25_outlier_iqr` kết hợp với sử dụng RobustScaler trong bước chuẩn hóa. Quyết định này dựa trên các lập luận sau:

- **Ý nghĩa thực tiễn:** Trong dữ liệu chất lượng không khí, các giá trị ngoại lai thường đại diện cho những đợt ô nhiễm nặng hoặc sự kiện cực đoan. Việc loại bỏ các giá trị này sẽ làm mất đi thông tin quan trọng, khiến mô hình giảm khả năng dự báo các tình huống ô nhiễm nghiêm trọng.
- **Hạn chế của chuẩn hóa truyền thống:** Nếu sử dụng StandardScaler, các giá trị ngoại lai sẽ kéo lệch giá trị trung bình và phương sai, dẫn đến làm méo mó phân phối của nhóm dữ liệu bình thường, từ đó giảm hiệu suất của các mô hình tuyến tính và tăng nhiễu cho các mô hình cây (XGBoost).



Hình 7: So sánh phân phối sau scale bằng RobustScaler và StandardScaler

Kết quả so sánh tại **Hình 7** cho thấy RobustScaler bảo toàn tốt hơn cấu trúc phân phối của dữ liệu $\text{PM}_{2.5}$ khi phần lớn các quan sát vẫn tập trung quanh trung vị và không bị ảnh hưởng đáng kể bởi các giá trị cực đoan. Ngược lại, StandardScaler nhạy cảm hơn với các ngoại lai có biên độ lớn, dẫn đến sự giãn rộng của thang đo và làm thay đổi mức độ phân tán của nhóm quan sát phổ biến. Do đó, RobustScaler được lựa chọn cho nghiên cứu này nhằm giảm tác động của ngoại lai trong quá trình chuẩn hóa nhưng vẫn duy trì các sự kiện ô nhiễm cực đoan có ý nghĩa đối với bài toán dự báo chất lượng không khí.

F. Chuẩn hóa phân phối dữ liệu

Bước cuối cùng trong giai đoạn tiền xử lý là chuẩn hóa dữ liệu. Việc đưa các đặc trưng về cùng một khoảng giá trị là cần thiết để đảm bảo các mô hình hội tụ nhanh hơn và ổn định hơn. Nhóm lựa chọn RobustScaler thay vì StandardScaler hoặc MinMaxScaler dựa trên các lý do sau:

- **Đặc điểm dữ liệu:** Nồng độ $\text{PM}_{2.5}$ và một số đặc trưng khí tượng có phân phối lệch phải mạnh và chứa nhiều giá trị ngoại lai, như đã phân tích tại **Hình 6**.
- **Ưu điểm của RobustScaler:** Khác với StandardScaler dựa trên giá trị trung bình và độ lệch chuẩn (vốn rất nhạy cảm với outlier), RobustScaler sử dụng trung vị và khoảng tứ phân vị. Điều này giúp quá trình chuẩn hóa không bị kéo lệch bởi các giá trị cực đoan, phù hợp với đặc tính của dữ liệu môi trường.

Để đảm bảo tính khách quan tuyệt đối và ngăn chặn hiện tượng rò rỉ dữ liệu, quy trình chuẩn hóa được thực hiện nghiêm ngặt: RobustScaler chỉ được huấn luyện trên tập Train, sau đó các tham số này được áp dụng transform cho tập Validation và Test.

Kết quả sau chuẩn hóa cho thấy phân phối của các đặc trưng trở nên cân bằng hơn, giúp mô hình Linear Regression hoạt động ổn định và cải thiện đáng kể hiệu suất tổng thể cho các mô hình cơ sở.

V. TRÍCH XUẤT ĐẶC TRƯNG VÀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)

A. Trích xuất đặc trưng (Feature Engineering)

Kỹ thuật đặc trưng là bước then chốt quyết định hiệu suất của mô hình dự báo. Sau khi hoàn tất tiền xử lý, nghiên cứu tập trung xây dựng ba nhóm đặc trưng chính nhằm khai thác tối đa tính chu kỳ, sự phụ thuộc thời gian và mối quan hệ phi tuyến giữa $PM_{2.5}$ với các yếu tố khí tượng.

1) Đặc trưng chu kỳ thời gian (Cyclical Encoding)

Nhóm sử dụng biến đổi sin và cos cho các biến *hour*, *month* và *dayofweek* thay vì giữ dạng số nguyên. Phương pháp này giải quyết vấn đề về tính liên tục của thời gian (ví dụ: giờ 23 và giờ 0 là liền kề). Việc chuyển đổi sang không gian lượng giác giúp mô hình học được tính tuần hoàn một cách tự nhiên và mượt mà, tránh việc hiểu sai khoảng cách giữa các thời điểm trong ngày hoặc trong tuần.

2) Đặc trưng quá khứ và trượt (Lag & Rolling Features)

Đây là nhóm đặc trưng cốt lõi để nắm bắt tính tự tương quan của chuỗi thời gian, bao gồm:

- **Đặc trưng trễ (Lag features):** Tạo các biến *pm25_lag_1*, *pm25_lag_3*, *pm25_lag_6*, *pm25_lag_24* và *pm25_lag_168*. Trong đó, *lag₁* nắm bắt biến động ngắn hạn, trong khi *lag₂₄* và *lag₁₆₈* giúp mô hình nhận diện quy luật lặp lại theo ngày và theo tuần.
- **Thống kê trượt (Rolling statistics):** Tính toán giá trị trung bình (mean), độ lệch chuẩn (std), giá trị lớn nhất (max) và nhỏ nhất (min) trên cửa sổ 24 giờ và 168 giờ. Các đặc trưng này cung cấp thông tin về xu hướng gần đây và độ biến động, đặc biệt quan trọng trong việc dự báo các đợt ô nhiễm tăng đột biến.

Tất cả các đặc trưng này được tính trên giá trị gốc và sử dụng hàm *shift(1)* để đảm bảo không có rò rỉ dữ liệu từ tương lai.

3) Đặc trưng tương tác khí tượng (Interaction Features)

Nhằm khai thác các mối quan hệ phi tuyến phức tạp, nhóm nghiên cứu xây dựng thêm các đặc trưng tương tác dựa trên kiến thức miền (domain knowledge). Các biến này được thiết kế để mô phỏng cách các yếu tố khí tượng tác động hiệp đồng lên nồng độ $PM_{2.5}$:

- **Đặc trưng tương tác kết hợp:** Xây dựng biến *temp_humidity* (temperature $\times$ humidity) và *wind_press_ratio* (wind_speed/pressure). Các biến tương tác này cho phép mô hình nắm bắt được các hiệu ứng kết hợp (ví dụ: nhiệt độ cao kết hợp với độ ẩm cao thường làm gia tăng nồng độ ô nhiễm) mà không cần phụ thuộc hoàn toàn vào khả năng tự học tương tác của các mô hình cây như Random Forest hay XGBoost.
- **Biến phái sinh:**
 - *precipitation_log*: Chuyển đổi lượng mưa sang thang đo logarit để giảm độ lệch của dữ liệu.


- *is_rain*: Biến nhị phân phân loại trạng thái có mưa, giúp mô hình nhận diện hiệu ứng "rửa trôi" khí quyển.
- *temp_diff_1* và *humidity_diff_1*: Tính toán mức chênh lệch giá trị tức thời để đo lường tốc độ biến thiên của thời tiết.

Sau khi thực hiện trích xuất đặc trưng và loại bỏ các dòng giá trị khuyết thiếu phát sinh do thao tác trễ (*shift*), bộ dữ liệu cuối cùng đạt được quy mô như sau:

- **Số lượng mẫu:** Tập Train (4.383 mẫu), Validation (1.248 mẫu), Test (1.521 mẫu).
- **Số lượng đặc trưng:** Tổng cộng 35 đặc trưng số (không bao gồm biến mục tiêu).

Kết quả này cung cấp một không gian đặc trưng phong phú, bao hàm đầy đủ thông tin về chu kỳ, lịch sử biến động và tương tác khí tượng, tạo nền tảng vững chắc cho quá trình huấn luyện mô hình dự báo.

B. Phân tích xu hướng thời gian của nồng độ $PM_{2.5}$




Hình 8: Biến động nồng độ $PM_{2.5}$ theo thời gian tại TP.HCM giai đoạn 07/2025–05/2026

Biểu đồ trong **Hình 8** thể hiện diễn biến nồng độ $PM_{2.5}$ tại TP.HCM trong giai đoạn từ tháng 07/2025 đến tháng 05/2026. Giá trị trung bình của chuỗi đạt khoảng $33,2 \mu\text{g}/\text{m}^3$, trong khi phần lớn các quan sát nằm trên mức hướng dẫn trung bình 24 giờ của WHO đối với $PM_{2.5}$ ($15 \mu\text{g}/\text{m}^3$) [1]. Kết quả này cho thấy nồng độ bụi mịn duy trì ở mức tương đối cao trong phần lớn thời gian của giai đoạn nghiên cứu.

Chuỗi thời gian cũng thể hiện sự thay đổi rõ rệt về mức độ và biên độ dao động theo thời gian. Trong giai đoạn từ cuối năm 2025 đến đầu năm 2026, tần suất xuất hiện các giá trị nồng độ cao gia tăng cùng với mức độ biến động lớn hơn so với các tháng trước đó. Ngoài ra, nhiều đỉnh nồng độ vượt $100 \mu\text{g}/\text{m}^3$ và đạt cực đại gần $170 \mu\text{g}/\text{m}^3$, cho thấy sự hiện diện của các giá trị cực trị và các đợt gia tăng nồng độ ngắn hạn. Những đặc điểm này phản ánh tính biến động cao của chuỗi $PM_{2.5}$, đồng thời cho thấy bài toán dự báo cần xem xét cả xu hướng dài hạn và các biến động cục bộ theo thời gian.

C. Phân tích ma trận tương quan Pearson



Hình 9: Ma trận tương quan Pearson giữa nồng độ $PM_{2.5}$ và các biến khí tượng

Nhằm đánh giá mối liên hệ tuyến tính giữa nồng độ bụi mịn $PM_{2.5}$ và các thông số khí tượng, ma trận tương quan Pearson được xây dựng và trình bày trong **Hình 9**.

Kết quả phân tích cho thấy nồng độ $PM_{2.5}$ có mối tương quan đa chiều với các biến khí tượng. Trong đó, tốc độ gió (wind speed) thể hiện hệ số tương quan âm lớn nhất với $PM_{2.5}$ ($r = -0,34$), phản ánh cơ chế khuếch tán khí quyển: sự gia tăng vận tốc gió thúc đẩy quá trình phát tán các hạt sol khí, từ đó làm giảm nồng độ ô nhiễm tại điểm quan trắc. Ngược lại, tương quan dương giữa áp suất khí quyển (pressure) và $PM_{2.5}$ ($r = +0,29$) cho thấy nồng độ bụi mịn có xu hướng gia tăng trong các điều kiện khí áp cao hơn. Kết quả này phù hợp với các điều kiện khí tượng kém thuận lợi cho quá trình khuếch tán chất ô nhiễm trong khí quyển.

Xét về mối quan hệ giữa các biến khí tượng, nhiệt độ (temperature) và độ ẩm (humidity) thể hiện tương quan âm mạnh với hệ số $r = -0,83$. Về mặt thống kê, mức độ tương quan cao này cho thấy nguy cơ xuất hiện hiện tượng đa cộng tuyến, có thể ảnh hưởng đến tính ổn định của các hệ số hồi quy trong các mô hình tuyến tính. Do đó, việc kiểm tra và đánh giá đa cộng tuyến là cần thiết nhằm đảm bảo độ tin cậy của mô hình.

Ngoài ra, hệ số tương quan giữa lượng mưa (precipitation) và $PM_{2.5}$ là rất thấp ($r = -0,06$), cho thấy mối quan hệ tuyến tính giữa hai biến là không rõ ràng. Kết quả này hàm ý rằng tác động của mưa đối với nồng độ bụi mịn có thể chưa được mô tả đầy đủ thông qua hệ số tương quan tuyến tính. Đây là một trong những cơ sở thực nghiệm để nhóm nghiên cứu xây dựng biến nhị phân is_rain nhằm mô phỏng hiệu ứng rửa trôi

của mưa đối với chất lượng không khí hiệu quả hơn so với việc sử dụng trực tiếp lượng mưa tuyệt đối.


D. Kiểm định tính dừng (Stationarity Test)

Tính dừng của chuỗi thời gian là yếu tố then chốt quyết định tính hợp lệ của các đặc trưng trễ và thống kê trượt (rolling statistics). Nghiên cứu này đã thực hiện đồng thời hai kiểm định: Augmented Dickey-Fuller (ADF) và Kwiatkowski-Phillips-Schmidt-Shin (KPSS) để có cái nhìn toàn diện.

Kết quả kiểm định trên 5000 quan sát đầu tiên cho thấy:

- **ADF Test:** Thống kê = $-8,2486$, $p\text{-value} \approx 0,0000 \rightarrow$ Bác bỏ mạnh giả thuyết chuỗi có đơn vị gốc (*non-stationary*).
- **KPSS Test:** Thống kê = $3,3934$, $p\text{-value} = 0,0100 \rightarrow$ Bác bỏ giả thuyết chuỗi dừng.

Sự mâu thuẫn giữa hai kết quả cho thấy chuỗi $PM_{2.5}$ có đặc tính dừng yếu ở mức kỳ vọng nhưng tồn tại hiện tượng phương sai thay đổi theo thời gian.



Hình 10: Rolling Mean và Rolling Standard Deviation (cửa sổ 168 giờ) của chuỗi $PM_{2.5}$

Điều này được minh chứng trực quan qua **Hình 10**: đường trung bình trượt khá ổn định, trong khi độ lệch chuẩn trượt biến động mạnh với nhiều đỉnh nhọn.


Nghiên cứu quyết định không thực hiện phép sai phân vì lý do sau:

- Việc sai phân sẽ làm mất ý nghĩa vật lý của nồng độ bụi ($\mu\text{g}/\text{m}^3$) và phá vỡ mối quan hệ trực tiếp giữa các biến khí tượng với biến mục tiêu.
- Đặc tính heteroscedasticity có thể được kiểm soát gián tiếp thông qua RobustScaler và việc xây dựng các đặc trưng đo lường biến động như $pm25_roll_std_24$ trong bước kỹ thuật đặc trưng.

Do đó, nhóm ưu tiên giữ nguyên chuỗi gốc để các mô hình học máy (XGBoost, Random Forest) tự thích nghi với đặc tính biến động thực tế của dữ liệu.

E. Phân rã chuỗi thời gian và hàm tự tương quan(ACF)

1) Phân tích phân rã chuỗi thời gian (Time Series Decomposition)



Hình 11: Phân rã chuỗi thời gian $PM_{2.5}$ theo mùa


Hình 11 minh họa kết quả phân rã chuỗi thời gian nồng độ $PM_{2.5}$ thông qua phương pháp phân rã cổ điển, tách biệt dữ liệu thành ba thành phần: xu thế (Trend), mùa vụ (Seasonal) và phần dư (Residual).

Về thành phần xu thế, dữ liệu cho thấy sự biến thiên không hằng định với biên độ dao động có xu hướng gia tăng vào giai đoạn cuối của chu kỳ quan sát (tháng 10/2025). Hiện tượng này phản ánh sự tác động của các yếu tố ngoại sinh mang tính chu kỳ dài hoặc sự thay đổi trong điều kiện khí tượng khu vực.

Thành phần mùa vụ thể hiện một đặc trưng dao động điều hòa với biên độ và tần số ổn định xuyên suốt giai đoạn nghiên cứu. Sự lặp lại tuần hoàn này là minh chứng điển hình cho tính chu kỳ ngắn hạn, tương ứng với chu kỳ sinh hoạt và phát thải theo ngày đêm.

Phân tích thành phần phần dư cho thấy sự hiện diện của các nhiễu ngẫu nhiên phân bố xung quanh giá trị trung bình. Tuy nhiên, sự xuất hiện của các giá trị cực đoan (outliers) với biên độ lớn trong tháng 10 cho thấy sự tồn tại của các sự kiện ô nhiễm đột biến. Điều này gợi ý rằng mô hình dự báo cần có khả năng thích ứng với các biến động phi tuyến tính và các cú sốc dữ liệu ngắn hạn để đảm bảo độ chính xác.

2) Phân tích hàm tự tương quan (ACF)



Hình 12: Hàm tự tương quan (ACF) của chuỗi $PM_{2.5}$

Nhằm đánh giá tính dừng và xác định cấu trúc tương quan của chuỗi thời gian, hàm tự tương quan (Autocorrelation Function


- ACF) được thực hiện với độ trễ lên đến 200 giờ (**Hình 12**). Biểu đồ ACF cho thấy hệ số tương quan giảm dần theo độ trễ (lag) nhưng không triệt tiêu nhanh, khẳng định chuỗi dữ liệu có tính phụ thuộc mạnh vào các giá trị quá khứ và không phải là một chuỗi ngẫu nhiên (white noise). Đặc biệt, sự xuất hiện của đỉnh tương quan có ý nghĩa thống kê tại $lag = 24$ (đường đứt nét màu đỏ) xác nhận sự tồn tại của chu kỳ ngày (daily seasonality). Điều này cho thấy nồng độ $PM_{2.5}$ tại thời điểm t có tương quan thuận mạnh mẽ với nồng độ tại thời điểm $t - 24$.

Đáng chú ý, hiện tượng lặp lại của các đỉnh tương quan tại $lag = 168$ (đường đứt nét màu xanh) minh chứng cho sự tồn tại của chu kỳ tuần (7 ngày $\times$ 24 giờ = 168 giờ). Sự tương quan này phản ánh quy luật phát thải gắn liền với chu kỳ hoạt động kinh tế - xã hội trong tuần. Kết quả phân tích ACF cung cấp căn cứ thực nghiệm quan trọng để định cấu hình các tham số mùa vụ cho mô hình SARIMA hoặc thiết lập cửa sổ thời gian (look-back window) cho các kiến trúc mạng nơ-ron tái hồi như LSTM, nhằm tối ưu hóa khả năng học các đặc trưng chu kỳ đa tầng của dữ liệu.

F. Phân tích biến thiên nồng độ bụi mịn $PM_{2.5}$

Kết quả quan trắc nồng độ bụi mịn $PM_{2.5}$ theo thời gian và mối tương quan với các yếu tố khí tượng được trình bày chi tiết qua các hình vẽ dưới đây.

1) Biến thiên theo giờ trong ngày




Hình 13: Sự phân bố nồng độ $PM_{2.5}$ theo chu kỳ 24 giờ

Kết quả cho thấy nồng độ bụi mịn có sự biến thiên rõ rệt theo thời điểm trong ngày. Cụ thể, nồng độ $PM_{2.5}$ có xu hướng tăng dần từ nửa đêm và đạt giá trị cực đại trong khoảng thời gian từ 06:00 đến 12:00.

Sự gia tăng này có thể được giải thích bởi sự kết hợp giữa hoạt động phát thải từ giao thông trong giờ cao điểm buổi sáng và hiện tượng nghịch nhiệt thường xảy ra vào sáng sớm, khiến các chất ô nhiễm bị giữ lại ở tầng thấp của khí quyển. Đáng chú ý, giá trị trung vị của phần lớn các khung giờ đều nằm trên mức hướng dẫn trung bình 24 giờ của Tổ chức Y tế Thế giới (WHO) đối với $PM_{2.5}$ là $15 \mu g/m^3$ [1], với nhiều giá trị ngoại lệ vượt mức $100 \mu g/m^3$, cho thấy các đợt ô nhiễm cục bộ nghiêm trọng.


2) Biến thiên theo tháng và tính mùa vụ



Hình 14: Sự phân bố nồng độ $PM_{2.5}$ theo mùa vụ

Phân tích tính mùa vụ qua **Hình 14** cho thấy nồng độ $PM_{2.5}$ dao động đáng kể theo các tháng trong năm. Ô nhiễm đạt đỉnh vào giai đoạn cuối năm và đầu năm, đặc biệt là tháng 12 và tháng 1. Ngược lại, nồng độ bụi mịn thấp nhất được ghi nhận vào khoảng giữa năm (tháng 7 và tháng 8). Hiện tượng này phản ánh đặc điểm khí tượng đặc trưng của khu vực: vào mùa đông, điều kiện khí quyển ổn định, ít gió và nhiệt độ thấp tạo điều kiện cho hiện tượng nghịch nhiệt xảy ra thường xuyên hơn, làm hạn chế khả năng khuếch tán của bụi mịn. Trong khi đó, vào mùa hè, lượng mưa tăng cao đóng vai trò là tác nhân rửa trôi (wet deposition), giúp giảm thiểu đáng kể nồng độ bụi trong không khí.

3) Tương quan giữa tốc độ gió và nồng độ $PM_{2.5}$



Hình 15: Biểu đồ phân tán $PM_{2.5}$ theo tốc độ gió kèm đường xu hướng

Mối quan hệ giữa tốc độ gió và nồng độ $PM_{2.5}$ được thể hiện qua biểu đồ phân tán (**Hình 5**). Kết quả phân tích hồi quy cho thấy một mối tương quan nghịch rõ rệt với hệ số góc (slope) là -1.46 .

Khi tốc độ gió ở mức thấp (< 5 km/h), nồng độ $PM_{2.5}$ tập trung ở mức cao với độ phân tán lớn, nhiều giá trị đạt ngưỡng nguy hại ($> 125 \mu\text{g}/\text{m}^3$). Khi tốc độ gió tăng dần, nồng độ bụi mịn giảm mạnh và có xu hướng ổn định hơn. Điều này khẳng

định vai trò quan trọng của vận tốc gió trong việc khuếch tán các hạt bụi mịn ra khỏi khu vực nguồn phát thải, từ đó làm giảm nồng độ ô nhiễm tại điểm đo.

VI. ĐÁNH GIÁ VÀ SO SÁNH DỮ LIỆU THEO DMES

A. Quản trị chất lượng dữ liệu theo khung tiêu chuẩn DMES

Nhằm đảm bảo tính khách quan và định lượng trong việc đánh giá chất lượng dữ liệu, nghiên cứu này áp dụng khung tiêu chuẩn Data Management Evaluation System (DMES). Hệ thống đánh giá được xây dựng dựa trên nhóm thành phần Dataset với bốn trụ cột cốt lõi:

- Tính toàn vẹn (Completeness):** Đo lường tỷ lệ dữ liệu hiện có so với tổng lượng dữ liệu kỳ vọng, đảm bảo không có sự thiếu hụt nghiêm trọng làm sai lệch kết quả thống kê.
- Tính chính xác (Accuracy):** Xác định mức độ sai lệch của giá trị đo so với các ngưỡng vật lý hợp lý của nồng độ $PM_{2.5}$, loại bỏ các giá trị không tưởng hoặc lỗi cảm biến.
- Tính nhất quán (Consistency):** Đảm bảo sự đồng nhất về định dạng, múi giờ và tần suất lấy mẫu giữa các nguồn cung cấp dữ liệu khác nhau.
- Tính kịp thời (Timeliness):** Đánh giá độ trễ trong quá trình cập nhật và xử lý dữ liệu từ API, đảm bảo tính cập nhật của chuỗi thời gian.

Việc thiết lập các tiêu chí này tạo ra một thước đo chuẩn hóa, cho phép kiểm chứng độ tin cậy của tập dữ liệu một cách hệ thống trước khi triển khai huấn luyện mô hình.

B. Thực thi quản trị dữ liệu theo tiêu chuẩn DMES

Để hiện thực hóa các tiêu chí của khung DMES, nghiên cứu triển khai một quy trình tiền xử lý dữ liệu nghiêm ngặt bao gồm bốn giai đoạn chính:

- Xử lý khuyết thiếu:** Áp dụng cơ chế nội suy tuyến tính theo thời gian cho các khoảng trống ngắn và loại bỏ các đứt gãy dữ liệu dài (gap detection) để đảm bảo tính liên tục của chuỗi thời gian.
- Làm sạch dữ liệu:** Loại bỏ các giá trị sentinel (giá trị đánh dấu lỗi) và chuẩn hóa quy mô dữ liệu bằng RobustScaler nhằm bảo toàn thông tin của các đỉnh ô nhiễm.
- Chuẩn hóa hệ thống:** Đồng bộ hóa múi giờ (Asia/Ho_Chi_Minh) và tần suất lấy mẫu từ các nguồn API khác nhau để đạt được sự nhất quán tuyệt đối.
- Thiết lập pipeline huấn luyện:** Triển khai quy trình phân tách dữ liệu trước khi xử lý (Split $\rightarrow$ Impute $\rightarrow$ Scale) nhằm ngăn chặn triệt để hiện tượng rò rỉ dữ liệu.

Sự kết hợp giữa khung tiêu chuẩn DMES và quy trình thực thi chi tiết này giúp đảm bảo rằng bộ dữ liệu đầu vào không chỉ sạch về mặt kỹ thuật mà còn đạt chuẩn về mặt quản trị dữ liệu khoa học.

C. So sánh đối chiếu với các nghiên cứu liên quan

Để đánh giá khách quan giá trị của bộ dữ liệu, nghiên cứu này thực hiện đối chiếu phương pháp quản trị dữ liệu với các

nghiên cứu [8] và [9] dựa trên bốn tiêu chí của khung DMES [6]. Kết quả tổng hợp được trình bày chi tiết trong Bảng II. Từ bảng đối chiếu, có thể thấy sự khác biệt rõ rệt về chiến lược quản trị dữ liệu. Về tính toàn vẹn, nghiên cứu [8] có ưu thế về độ phủ không gian thông qua mô phỏng WRF. Tuy nhiên, nghiên cứu này đạt được sự tối ưu ở tầng dữ liệu thông qua các kỹ thuật chuẩn hóa và trích xuất đặc trưng, giúp tăng độ nhạy với các đỉnh ô nhiễm thực tế. Đặc biệt, việc tuân thủ nghiêm ngặt quy trình chống rò rỉ dữ liệu và tối ưu hóa pipeline cho dự báo ngắn hạn giúp bộ dữ liệu đạt được độ tin cậy thực nghiệm cao và tính ứng dụng thực tế lớn.

D. Phân tích ưu điểm và giới hạn của bộ dữ liệu

Ưu điểm nổi bật của bộ dữ liệu nằm ở độ tin cậy cao nhờ nguồn cung cấp uy tín và quy trình tiền xử lý khắt khe. Cấu trúc dữ liệu được tối ưu hóa thông qua việc xác định các khoảng trễ (1, 3, 6, 24, 168h) dựa trên phân tích hàm tự tương quan (ACF) và tự tương quan riêng phần (PACF). Đồng thời, khả năng chống nhiễu được tăng cường nhờ chiến lược gán cờ ngoại lai, giúp mô hình ổn định trước các biến động cực đoan.

Tuy nhiên, nghiên cứu vẫn tồn tại một số giới hạn:

- **Phụ thuộc hạ tầng:** Chất lượng dữ liệu phụ thuộc vào hệ thống vận hành của OpenAQ, dẫn đến rủi ro mất dữ liệu cục bộ không thể khắc phục.
- **Phạm vi biến số:** Bộ dữ liệu hiện tại chủ yếu tập trung vào yếu tố khí tượng, chưa tích hợp các biến số động như mật độ giao thông hoặc hoạt động công nghiệp thời gian thực.

E. Đánh giá và phân tích hiệu năng mô hình

Nhằm đánh giá hiệu quả của quy trình tiền xử lý và kỹ thuật xây dựng đặc trưng, ba mô hình cơ sở gồm Linear Regression, Random Forest và XGBoost được huấn luyện và so sánh trên cùng tập kiểm tra. Hiệu năng được đánh giá thông qua các chỉ số MAE, RMSE, R^2 , MAPE cùng tỷ lệ dự báo chính xác trong khoảng sai số $\pm 5, \mu\text{g}/\text{m}^3$ và $\pm 10, \mu\text{g}/\text{m}^3$.

Mô hình Linear Regression cho thấy hiệu năng thấp nhất và kém ổn định, đặc biệt khi đối mặt với hiện tượng đa cộng tuyến giữa các biến Lag, khẳng định mối quan hệ giữa khí tượng và ô nhiễm là phi tuyến. Random Forest cải thiện đáng kể sai số MAE và RMSE nhờ khả năng xử lý đặc trưng phi tuyến, nhưng vẫn xuất hiện dấu hiệu quá khớp trên tập huấn luyện.



Hình 16: So sánh hiệu năng của các mô hình Linear Regression, Random Forest và XGBoost trên tập kiểm tra dựa trên các chỉ số MAE, RMSE và R^2 .

1) Phân tích mô hình Linear Regression

Mô hình Linear Regression được sử dụng như một mô hình cơ sở (baseline) nhằm thiết lập ngưỡng hiệu năng tham chiếu cho bài toán dự báo. Kết quả thực nghiệm cho thấy mô hình đạt hiệu năng thấp nhất trong số các phương pháp được khảo sát. Nguyên nhân có thể xuất phát từ việc mô hình tuyến tính khó khai thác hiệu quả tập đặc trưng có cấu trúc phức tạp, bao gồm các biến trễ (lag features), thống kê trượt (rolling features) và các đặc trưng tương tác khí tượng. Kết quả này cho thấy mối quan hệ giữa nồng độ $PM_{2.5}$ và các yếu tố khí tượng mang tính phi tuyến đáng kể, khiến Linear Regression gặp hạn chế trong việc mô hình hóa đầy đủ các biến động thực tế của chuỗi thời gian.


2) Phân tích mô hình Random Forest

Random Forest cải thiện đáng kể sai số MAE và RMSE nhờ khả năng xử lý dữ liệu phi tuyến và tính bền vững trước hiện tượng đa cộng tuyến. Tuy nhiên, khi phân tích phân phối phần dư (Residuals), mô hình vẫn cho thấy dấu hiệu overfitting trên tập huấn luyện, dẫn đến hiện tượng “làm phẳng” các đỉnh ô nhiễm (pollution peaks), khiến sai số tăng cao tại các thời điểm nồng độ $PM_{2.5}$ biến động cực đoan.

3) Phân tích mô hình XGBoost và kiểm định thống kê

XGBoost đạt hiệu năng tối ưu nhất trên tất cả các metric. Sự vượt trội này không chỉ thể hiện qua các con số MAE/RMSE thấp nhất mà còn được xác nhận thông qua các kiểm định thống kê khắt khe:

- **Diebold–Mariano Test:** Kết quả cho thấy sự cải thiện của XGBoost so với Random Forest và Linear Regression là có ý nghĩa thống kê ($p\text{-value} < 0.05$), khẳng định XGBoost thực sự tốt hơn chứ không phải do ngẫu nhiên.
- **Paired t-test:** Kết quả kiểm định t-test trên sai số tuyệt đối tiếp tục xác nhận ưu thế vượt trội của XGBoost với mức ý nghĩa $\alpha = 0.05$.
- **Phân tích phần dư (Residual Analysis):** Biểu đồ Q-Q plot và ACF của phần dư cho thấy sai số của XGBoost phân phối gần với phân phối chuẩn và không còn hiện tượng tự tương quan đáng kể, chứng minh mô hình đã khai thác hết các tín hiệu (signals) từ tập dữ liệu.



Hình 17: Phân tích phần dư (Residual Analysis) của mô hình XGBoost bao gồm phân phối phần dư, biểu đồ Q-Q Plot và hàm tự tương quan (ACF) của sai số.

Bảng II: So sánh phương pháp quản trị dữ liệu theo khung DMES

Tiêu chí	Nghiên cứu [8]	Nghiên cứu [9]	Nghiên cứu này
Completeness	Dữ liệu lưới toàn thành phố qua mô phỏng vật lý WRF.	Tập dữ liệu lớn phục vụ huấn luyện mạng sâu.	Dữ liệu thực nghiệm từ 5 trạm; nội suy MAR ($\leq 3h$) giữ tính liên tục chuỗi thời gian.
Accuracy	Phụ thuộc mô hình WRF, dễ gặp sai số hệ thống (<i>bias</i>).	Tinh chỉnh kiến trúc mô hình <i>Deep Learning</i> .	Tập trung tăng dữ liệu qua <i>Feature Engineering</i> , <i>Cyclical Encoding</i> , <i>RobustScaler</i> .
Consistency	Đảm bảo định dạng dữ liệu cơ bản.	Đảm bảo định dạng dữ liệu cơ bản.	Chuẩn hóa múi giờ và tần suất 1h; quy trình Split $\rightarrow$ Impute $\rightarrow$ Scale chống rò rỉ.
Timeliness	Dự báo theo vùng và dài hạn qua mô phỏng.	Tối ưu hóa sai số dự báo cho tập dữ liệu lớn.	Dự báo ngắn hạn với khoảng nhìn trước 1h; pipeline tiền xử lý tự động hóa cho cảnh báo tức thời.

VII. Kết luận và Hướng phát triển

A. Kết luận

Nghiên cứu đã xây dựng thành công một quy trình tiền xử lý dữ liệu hệ thống cho bài toán dự báo nồng độ $PM_{2.5}$ tại TP.HCM. Thông qua việc tích hợp dữ liệu đa nguồn, áp dụng khung đánh giá DMES để làm sạch và chuẩn hóa, cùng kỹ thuật phân tích ACF/PACF để tối ưu hóa các đặc trưng trễ, đề tài đã tạo ra một tập dữ liệu chất lượng cao, đảm bảo tính toàn vẹn và khách quan.

Kết quả thực nghiệm cho thấy, chính quy trình tiền xử lý bài bản và kỹ thuật trích xuất đặc trưng chi tiết là yếu tố then chốt giúp mô hình XGBoost đạt được hiệu năng tối ưu. Điều này khẳng định một luận điểm quan trọng trong bài toán dự báo chuỗi thời gian: chất lượng và cấu trúc của dữ liệu đầu vào có tác động quyết định đến kết quả dự báo, đôi khi quan trọng hơn cả việc lựa chọn các thuật toán phức tạp.

B. Hạn chế của nghiên cứu

Mặc dù đạt được những kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế nhất định về mặt vận hành và phạm vi dữ liệu:

- **Sự phụ thuộc vào nguồn dữ liệu:** Việc khai thác dữ liệu thông qua API bên thứ ba tiềm ẩn rủi ro về tính kịp thời và độ ổn định khi triển khai hệ thống trong môi trường thực tế.
- **Phạm vi biến số:** Tập đặc trưng hiện tại mới chỉ tập trung vào các biến khí tượng và dữ liệu lịch sử, chưa bao quát được các tác nhân động như mật độ giao thông hoặc hoạt động công nghiệp thời gian thực. Điều này có thể làm hạn chế khả năng giải thích toàn diện đối với các biến động cực đoan của nồng độ $PM_{2.5}$.

C. Hướng phát triển trong tương lai

Để nâng cao hơn nữa hiệu quả của hệ thống dự báo, một số hướng phát triển trong tương lai được đề xuất như sau:

- **Tự động hóa quy trình:** Phát triển hệ thống tiền xử lý tự động hóa hoàn toàn để nâng cao tính ổn định và khả năng vận hành thực tế cho các hệ thống cảnh báo tức thời.

- **Mở rộng nguồn dữ liệu:** Tích hợp thêm dữ liệu từ mạng lưới cảm biến chi phí thấp hoặc dữ liệu vệ tinh nhằm cải thiện độ phủ không gian và tăng độ chi tiết cho mô hình quan trắc.
- **Nâng cấp kiến trúc mô hình:** Trên nền tảng dữ liệu đã được chuẩn hóa và tối ưu đặc trưng, có thể triển khai các mô hình học sâu Deep Learning như LSTM, GRU hoặc Transformer để khai thác sâu hơn các phụ thuộc dài hạn trong chuỗi thời gian, từ đó nâng cao độ chính xác dự báo cho bài toán chất lượng không khí tại TP.HCM.
- **Phát triển hệ thống cảnh báo chất lượng không khí:** Trên nền tảng dữ liệu và mô hình dự báo đã xây dựng, có thể phát triển ứng dụng Web hoặc Mobile phục vụ giám sát và cảnh báo chất lượng không khí theo thời gian thực. Bên cạnh việc cung cấp các chỉ số kỹ thuật như $PM_{2.5}$ và AQI, một hướng nghiên cứu tiềm năng là phát triển các cơ chế diễn giải rủi ro sức khỏe theo hướng trực quan và dễ tiếp cận hơn đối với người dùng phổ thông. Cách tiếp cận này cho phép chuyển đổi kết quả dự báo thành các chỉ báo có ý nghĩa thực tiễn đối với sức khỏe, giúp người dùng dễ dàng nhận thức mức độ nguy hiểm của ô nhiễm không khí và đưa ra các biện pháp phòng ngừa phù hợp.

Tài liệu

- [1] World Health Organization, "Ambient (Outdoor) Air Pollution," Oct. 24, 2024. [Online]. Available: [https://www.who.int/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health). [Accessed: May 1, 2024].
- [2] World Health Organization, "Air Pollution in Viet Nam," 2018. [Online]. Available: <https://www.who.int/vietnam/health-topics/air-pollution>. [Accessed: May 1, 2024].
- [3] World Bank, "Ho Chi Minh City Development Policy Operation - 2 (P171216)," Jun. 2, 2021. [Online]. Available: <https://projects.worldbank.org/en/projects-operations/project-detail/P171216>. [Accessed: May 1, 2024].
- [4] OpenAQ, "Measurements," OpenAQ Documentation, 2026. [Online]. Available: <https://docs.openaq.org>. [Accessed: Apr. 23, 2026].
- [5] Open-Meteo, "Historical Weather API," 2026. [Online]. Available: <https://open-meteo.com/en/docs/historical-weather-api>. [Accessed: Apr. 23, 2026].
- [6] S. Zhou, W. Wang, L. Zhu, Q. Qiao, and Y. Kang, "Deep-Learning Architecture for $PM_{2.5}$ Concentration Prediction: A Review,"

Environmental Science and Ecotechnology, vol. 21, Art. no. 100400, 2024. doi: 10.1016/j.esec.2024.100400.

- [7] I. E. Agbehadji and I. C. Obagbuwa, "Systematic Review of Machine Learning and Deep Learning Techniques for Spatiotemporal Air Quality Prediction," *Atmosphere*, vol. 15, no. 11, Art. no. 1352, 2024. doi: 10.3390/atmos15111352.
- [8] V. T. T. Minh *et al.*, "PM_{2.5} Forecast System by Using Machine Learning and WRF Model: A Case Study of Ho Chi Minh City, Vietnam," *Aerosol and Air Quality Research*, vol. 21, no. 12, 2021. doi: 10.4209/aaqr.210106.
- [9] P. H. Nguyen, N. K. Dao, and L. S. P. Nguyen, "Development of Machine Learning and Deep Learning Prediction Models for PM_{2.5} in Ho Chi Minh City, Vietnam," *Atmosphere*, vol. 15, no. 10, Art. no. 1163, 2024. doi: 10.3390/atmos15101163.
- [10] IQAir, "Air Quality API Documentation," 2026. [Online]. Available: <https://www.iqair.com/air-pollution-data-api>. [Accessed: Apr. 23, 2026].
- [11] World Air Quality Index Project (WAQI), "API Documentation," 2026. [Online]. Available: <https://aqicn.org/api/>. [Accessed: Apr. 23, 2026].
- [12] PurpleAir, "Historical Data API Documentation," 2026. [Online]. Available: <https://community.purpleair.com>. [Accessed: Apr. 23, 2026].
- [13] OpenWeather, "Weather API Documentation," 2026. [Online]. Available: <https://openweathermap.org/api>. [Accessed: Apr. 23, 2026].
- [14] NOAA National Centers for Environmental Information, "Climate Data Online Web Services Documentation," 2026. [Online]. Available: <https://www.ncei.noaa.gov/cdo-web/webservices/v2>. [Accessed: Apr. 23, 2026].